

**UNIVERSIDADE FEDERAL DE PELOTAS**  
**Centro de Desenvolvimento Tecnológico**  
**Curso de Bacharelado em Engenharia de Computação**



Trabalho de Conclusão de Curso

**Plataforma Híbrida de Instrumentação para Biosinais: Redução de Ruído com  
Hardware de Precisão e Inteligência Artificial**

**Gerson Leite de Menezes**

Pelotas, 2026

**Gerson Leite de Menezes**

**Plataforma Híbrida de Instrumentação para Biosinais: Redução de Ruído com  
Hardware de Precisão e Inteligência Artificial**

Trabalho de Conclusão de Curso apresentado  
ao Centro de Desenvolvimento Tecnológico da  
Universidade Federal de Pelotas, como requisito  
parcial à obtenção do título de Bacharel em En-  
genharia de Computação.

Orientador: Prof. Dr. Alan Carlos Junior Rossetto

Pelotas, 2026

**Insira AQUI a ficha catalográfica  
Quando finalizado o trabalho, deve ser  
solicitada através do Sistema Cobalto  
Biblioteca – Cadastro – Ficha catalográfica.**

**Gerson Leite de Menezes**

**Plataforma Híbrida de Instrumentação para Biosinais: Redução de Ruído com  
Hardware de Precisão e Inteligência Artificial**

Trabalho de Conclusão de Curso aprovado, como requisito parcial, para obtenção do grau de Bacharel em Engenharia de Computação, Centro de Desenvolvimento Tecnológico, Universidade Federal de Pelotas.

**Data da Defesa:** 30 de Julho de 2026

**Banca Examinadora:**

Prof. Dr. Alan Carlos Junior Rossetto (orientador)  
Doutor em Ciência da Computação pela UFRGS.

Prof. Dr. Membro da Banca 1  
Doutor em ... pela ...

Prof. Dr. Membro da Banca 2  
Doutor em ... pela ...

Dedico este trabalho aos meus pais e à minha namorada Gessyca, pelo apoio constante e incentivo durante toda a minha jornada acadêmica.

## **Agradecimentos**

Agradeço aos meus familiares e amigos, que sempre estiveram ao meu lado. Ao meu orientador, Prof. Alan Rossetto, pela oportunidade e confiança.

*“A simplicidade é o grau máximo de sofisticação.”*

— LEONARDO DA VINCI

## Resumo

MENEZES, Gerson Leite de. **Plataforma Híbrida de Instrumentação para Biosinais: Redução de Ruído com Hardware de Precisão e Inteligência Artificial.** Orientador: Alan Carlos Junior Rossetto. 2026. 32 f. Trabalho de Conclusão de Curso (Engenharia de Computação) – Centro de Desenvolvimento Tecnológico, Universidade Federal de Pelotas, Pelotas, 2026.

A aquisição de biosinais, como o Eletrocardiograma (ECG) e a Eletromiografia (EMG), é fundamental na saúde e pesquisa, mas estes sinais de baixa amplitude são suscetíveis a ruídos da rede elétrica e artefatos de movimento. Equipamentos profissionais de alta fidelidade possuem custo elevado, enquanto soluções de baixo custo carecem de precisão. Este trabalho propõe o desenvolvimento de uma plataforma híbrida de instrumentação para a aquisição e análise de biosinais, combinando um hardware de alta precisão com pós-processamento via software inteligente. A abordagem se baseia em duas frentes de atuação: primeiramente, o projeto de um *shield* de condicionamento analógico de baixo ruído, responsável por amplificar e filtrar o sinal na sua origem. Em seguida, os dados adquiridos são processados em um computador por um algoritmo de Inteligência Artificial, que atua como uma segunda camada de filtragem adaptativa para atenuar ruídos complexos. Como principal contribuição, espera-se obter uma plataforma funcional de baixo custo que demonstre uma melhora significativa na relação sinal-ruído, validada através da aquisição de sinais reais de ECG e EMG.

Palavras-chave: instrumentação biomédica; processamento de sinais; inteligência artificial; hardware de precisão.

## **Abstract**

MENEZES, Gerson Leite de. **Hybrid Instrumentation Platform for Biosignals: Noise Reduction with Precision Hardware and Artificial Intelligence.** Advisor: Alan Carlos Junior Rossetto. 2026. 32 f. Undergraduate Thesis (Computer Engineering) – Technology Development Center, Federal University of Pelotas, Pelotas, 2026.

The acquisition of biosignals, such as Electrocardiogram (ECG) and Electromyography (EMG), is fundamental in health and research, but these low-amplitude signals are susceptible to power line noise and motion artifacts. High-fidelity professional equipment is expensive, while low-cost solutions lack precision. This work proposes the development of a hybrid instrumentation platform for the acquisition and analysis of biosignals, combining high-precision hardware with intelligent software post-processing. The approach is based on two fronts: firstly, the design of a low-noise analog conditioning shield, responsible for amplifying and filtering the signal at its source. Next, the acquired data is processed on a computer by an Artificial Intelligence algorithm, acting as a second layer of adaptive filtering to attenuate complex noises. As a main contribution, a functional low-cost platform demonstrating a significant improvement in the signal-to-noise ratio is expected, validated through the acquisition of real ECG and EMG signals.

**Keywords:** biomedical instrumentation; signal processing; artificial intelligence; precision hardware.

## **Lista de Figuras**

## **Lista de Tabelas**

Tabela 1	Definição dos Componentes Críticos do Hardware . . . . .	26
----------	--	----

## **Lista de Abreviaturas e Siglas**

ADC	Analog-to-Digital Converter
CMRR	Common-Mode Rejection Ratio
CNN	Convolutional Neural Network
DAE	Denoising Autoencoder
DAQ	Data Acquisition
ECG	Eletrocardiograma
EMG	Eletromiografia
ML	Machine Learning
IA	Inteligência Artificial
PCB	Printed Circuit Board
RNAs	Redes Neurais Artificiais
sEMG	Surface Electromyography
SNR	Signal-to-Noise Ratio
SoC	System on Chip

# Sumário

<b>1 Introdução . . . . .</b>	14
<b>1.1 Objetivos . . . . .</b>	15
1.1.1 Objetivo Geral . . . . .	15
1.1.2 Objetivos Específicos . . . . .	15
<b>2 Fundamentação Teórica . . . . .</b>	16
<b>2.1 Biosinais . . . . .</b>	16
2.1.1 Eletrocardiograma (ECG) . . . . .	16
2.1.2 Morfologia e Intervalos do ECG . . . . .	17
2.1.3 Eletromiografia (EMG) . . . . .	18
<b>2.2 Instrumentação e Condicionamento de Sinais . . . . .</b>	19
<b>2.3 Filtragem Digital e Inteligência Artificial . . . . .</b>	20
2.3.1 Filtragem Digital . . . . .	20
2.3.2 Inteligência Artificial (IA) . . . . .	20
2.3.3 Aprendizado de Máquina ( <i>Machine Learning</i> ) . . . . .	21
2.3.4 Redes Neurais Artificiais . . . . .	21
2.3.5 Aprendizado Profundo ( <i>Deep Learning</i> ) . . . . .	21
2.3.6 Redes Neurais Convolucionais (CNNs) . . . . .	22
2.3.7 Autoencoders . . . . .	22
<b>3 Trabalhos Relacionados . . . . .</b>	24
<b>4 Metodologia e Desenvolvimento . . . . .</b>	25
<b>4.1 Definição da Arquitetura do Sistema . . . . .</b>	25
4.1.1 Detalhamento dos Blocos Funcionais . . . . .	25
<b>4.2 Projeto do Hardware de Aquisição . . . . .</b>	26
4.2.1 Seleção de Componentes Críticos . . . . .	26
4.2.2 Dimensionamento dos Filtros Analógicos . . . . .	26
<b>4.3 Desenvolvimento do Software e Interface . . . . .</b>	27
4.3.1 Ambiente de Simulação e Validação . . . . .	27
4.3.2 Interface de Visualização em Tempo Real . . . . .	27
<b>4.4 Processamento Digital e Inteligência Artificial . . . . .</b>	28
<b>4.5 Integração e Testes do Sistema . . . . .</b>	28
<b>5 Resultados . . . . .</b>	29
<b>6 Conclusão . . . . .</b>	30
<b>Referências . . . . .</b>	31

# 1 Introdução

A instrumentação biomédica dedica-se ao desenvolvimento de sistemas para medir e monitorar sinais fisiológicos. Dentre estes, os biopotenciais — sinais elétricos gerados por atividade celular, como o Eletrocardiograma (ECG) e a Eletromiografia (EMG) — são dos mais estudados e clinicamente relevantes. Historicamente, a aquisição destes sinais era restrita a ambientes clínicos controlados, utilizando equipamentos analógicos volumosos e de alto custo (Goldberger et al., 2000).

Com o avanço da microeletrônica, tornou-se viável o desenvolvimento de sistemas de aquisição de dados (DAQ) portáteis e de baixo custo, frequentemente baseados em microcontroladores. Plataformas como o Arduino popularizaram o acesso a essas tecnologias. No entanto, a aquisição de biosinais apresenta um desafio de engenharia significativo: os sinais de interesse possuem amplitude muito baixa (na faixa de microvolts a milivolts) e seu espectro de frequência se sobrepõe a diversas fontes de ruído, notadamente o ruído da rede elétrica (60 Hz e seus harmônicos) e artefatos de movimento (Pathak et al., 2025).

Soluções convencionais de baixo custo frequentemente falham em mitigar esse ruído de forma eficaz. O conversor Analógico-Digital (ADC) nativo de microcontroladores como o ATmega328 (do Arduino Uno) possui resolução e linearidade insuficientes, e o projeto de circuitos de condicionamento analógico — a etapa de amplificação e filtragem que antecede a digitalização — é crítico. Um projeto inadequado de *front-end* analógico pode contaminar irremediavelmente o sinal antes mesmo que ele seja processado digitalmente (Kim; Ko, 2016).

Por outro lado, o processamento digital de sinais e, mais recentemente, a Inteligência Artificial, trouxeram novas ferramentas para o tratamento de sinais ruidosos. Contudo, para ruídos complexos e não-estacionários, métodos de filtragem adaptativa (Widrow et al., 1975) e algoritmos baseados em aprendizado de máquina demonstram superioridade. Redes neurais, como as convolucionais (CNNs) e autoencoders, têm mostrado resultados promissores na reconstrução e remoção de ruído de sinais de ECG (Chandra; Sharma; Kasliwal, 2018; Lomoio; Veltri; Guzzi; Liò, 2024).

Este trabalho se justifica pela lacuna existente entre os sistemas de instrumentação de baixo custo e a necessidade de alta fidelidade na aquisição de biosinais. A inovação do projeto reside na abordagem híbrida: em vez de depender unicamente do

hardware ou do software, propõe-se uma sinergia entre ambos. O projeto se distingue de outros por não tentar corrigir um sinal de baixa qualidade (adquirido por hardware genérico) apenas com software. A hipótese é que, ao projetar um hardware de precisão dedicado (um *shield* analógico de baixo ruído), o sinal entregue ao processador será de qualidade muito superior, permitindo que a camada de Inteligência Artificial atue de forma mais fina e eficaz.

## 1.1 Objetivos

### 1.1.1 Objetivo Geral

Desenvolver e validar uma plataforma híbrida de instrumentação para aquisição de biosinais (ECG e EMG), que utilize a sinergia entre um *shield* de condicionamento analógico de precisão e algoritmos de Inteligência Artificial para maximizar a relação sinal-ruído.

### 1.1.2 Objetivos Específicos

- Realizar um estudo aprofundado sobre a natureza dos biosinais, técnicas de condicionamento analógico e métodos de IA;
- Projetar e simular um circuito de *front-end* analógico de baixo ruído, contendo amplificação de instrumentação e filtragem ativa;
- Implementar e validar o protótipo de hardware do *shield*, primeiro em protoboard e, subsequentemente, em placa de circuito impresso (PCB);
- Desenvolver o software base de aquisição (firmware) e uma interface de visualização em tempo real;
- Implementar e treinar um modelo de Inteligência Artificial para a filtragem adaptativa de ruído;
- Integrar o hardware e o software em uma plataforma funcional;
- Validar o sistema completo através da aquisição de sinais reais, comparando quantitativamente a relação sinal-ruído.

## 2 Fundamentação Teórica

### 2.1 Biosinais

Os biosinais são registros de fenômenos biológicos que variam no tempo, podendo ser de natureza elétrica, mecânica ou química. No contexto deste trabalho, o foco recai sobre os biopotenciais, sinais elétricos gerados pela atividade eletroquímica de células excitáveis, especificamente o coração e os músculos esqueléticos; eles serão obtidos através de eletrodos do tipo sEMG (Surface Electromyography).

#### 2.1.1 Eletrocardiograma (ECG)

O Eletrocardiograma (ECG) é o registro gráfico da atividade elétrica do coração, captado por eletrodos posicionados na superfície corporal. Ele representa a soma espacial e temporal dos potenciais de ação das fibras miocárdicas durante o ciclo cardíaco. A análise morfológica do ECG é fundamental para o diagnóstico de diversas patologias, como arritmias, isquemias e infartos.

Segundo (Souto, 2016), um ciclo cardíaco normal em um traçado de ECG é composto por uma sequência de deflexões características, denominadas ondas P, Q, R, S e T. A Onda P representa a despolarização atrial, ou seja, a ativação elétrica dos átrios que antecede a sua contração mecânica. É tipicamente uma onda arredondada e de pequena amplitude (0,1 a 0,2 mV). O Complexo QRS corresponde à despolarização ventricular. É a estrutura mais proeminente do ECG, caracterizada por uma deflexão rápida e de grande amplitude (até 1-2 mV), refletindo a grande massa muscular dos ventrículos. A Onda T representa a repolarização ventricular, momento em que o miocárdio recupera seu potencial de repouso para o próximo batimento.

A padronização do registro de ECG é essencial para a análise clínica. O sinal é tradicionalmente impresso sobre uma grade milimetrada padrão, onde cada eixo possui um significado físico preciso. O eixo horizontal representa o tempo: a velocidade padrão de registro é de 25 mm/s. Assim, cada subdivisão menor (1 mm) corresponde a 0,04 segundos (40 ms), e cada quadrado maior (5 mm, composto por 5 quadrinhos) corresponde a 0,20 segundos (200 ms). O eixo vertical representa a voltagem (amplitude): a calibração padrão é de 10 mm/mV. Portanto, cada subdivisão menor (1 mm) na vertical representa 0,1 milivolts (0,1 mV), e cada quadrado maior (5 mm) representa 0,5 mV. Essa padronização permite que médicos e sistemas automatizados

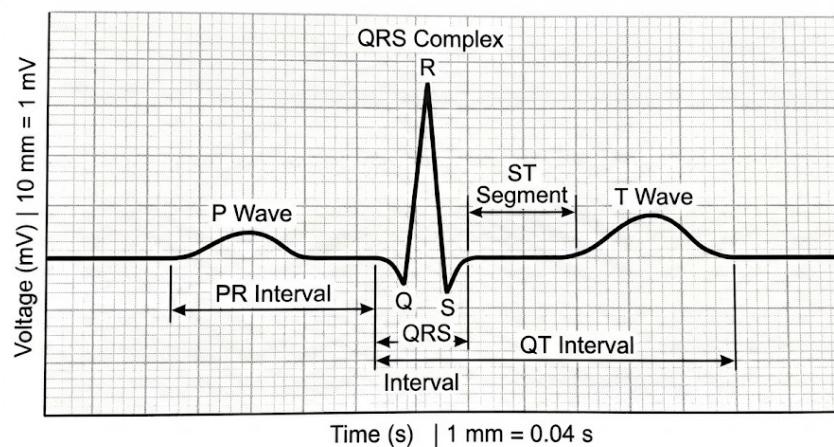


Figura 1 – Sinal de ECG típico mostrando as ondas P, QRS e T.

calculem a frequência cardíaca e a duração de intervalos críticos (como o intervalo PR e o segmento ST) visualmente.

### 2.1.2 Morfologia e Intervalos do ECG

A análise clínica do ECG baseia-se não apenas na presença das ondas, mas na duração e amplitude dos intervalos entre elas. Segundo (Souto, 2016) e ilustrado na Figura 1, a atividade elétrica cardíaca normal segue um padrão hierárquico e temporal rigoroso:

- **Onda P:** A primeira deflexão do ciclo, correspondente à despolarização atrial. Sua duração normal é inferior a 0,10 s e sua voltagem não deve exceder 0,25 mV. Alterações nesta onda podem indicar sobrecarga atrial.
- **Intervalo PR:** Compreende o tempo desde o início da onda P até o início do complexo QRS. Representa o retardamento fisiológico da condução elétrica no nó atrioventricular, essencial para permitir o enchimento ventricular antes da contração. Sua duração normal varia entre 0,12 s e 0,20 s.
- **Complexo QRS:** Representa a despolarização ventricular. É composto por três ondas: a onda Q (primeira deflexão negativa), a onda R (primeira deflexão positiva) e a onda S (deflexão negativa após a onda R). A duração normal do complexo é de 0,06 s a 0,10 s. Um alargamento deste complexo geralmente indica bloqueios de ramo ou condução ventricular aberrante (Souto, 2016).
- **Segmento ST e Onda T:** O segmento ST reflete o período refratário absoluto dos ventrículos (início da repolarização), devendo estar nivelado com a linha de base (isoelétrico). A onda T representa a repolarização ventricular propriamente dita.

A correta identificação destas estruturas no sinal ruidoso é o principal desafio dos sistemas de monitoramento automático, visto que artefatos de movimento (comuns na EMG) podem mimetizar a alta frequência do complexo QRS ou distorcer a linha de base do segmento ST.

### 2.1.3 Eletromiografia (EMG)

A eletromiografia (EMG) é uma técnica utilizada para o monitoramento da atividade elétrica das membranas excitáveis das células musculares. O sinal eletromiográfico representa a soma algébrica dos potenciais de ação das fibras musculares ativas detectados em uma determinada área (Marchetti; Duarte, 2006). Essa técnica é amplamente utilizada tanto em análises clínicas, como no estudo da marcha, quanto em aplicações de controle biomédico, pois fornece informações sobre o tempo de ativação e a intensidade da contração muscular.

Para a aquisição do sinal, comumente utilizam-se eletrodos de superfície (sEMG), que são dispositivos não invasivos aderidos à pele. A interface eletrodo-pele atua como um transdutor que capta a corrente iônica gerada nos músculos e a converte em corrente eletrônica para o sistema de instrumentação. Segundo (Marchetti; Duarte, 2006), a configuração bipolar é a mais adequada para esse tipo de aplicação. Nela, dois eletrodos de detecção são posicionados sobre o ventre muscular e um terceiro eletrodo (referência) é colocado em uma região eletricamente neutra. Essa configuração permite o uso de amplificação diferencial, fundamental para eliminar ruídos de modo comum que afetam ambos os eletrodos de detecção.

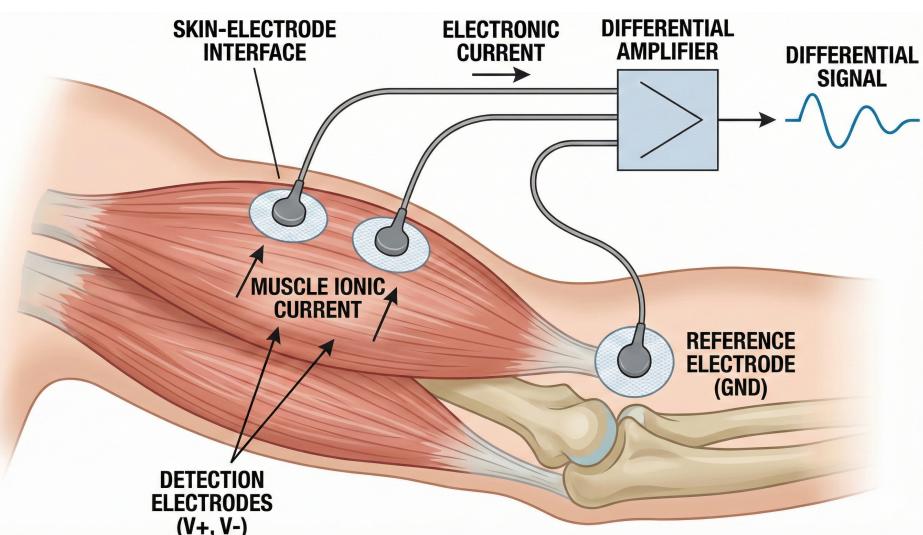


Figura 2 – Aquisição de biosinais utilizando-se eletrodos de superfícies

O sinal de EMG bruto é estocástico e apresenta frequências que variam tipicamente entre 10 Hz e 500 Hz, com amplitudes na faixa de microvolts a milivolts (Marchetti; Duarte, 2006). Devido a essa natureza complexa, a análise do sinal geralmente requer processamento no domínio do tempo ou da frequência. Uma das técnicas mais

comuns para quantificar a intensidade da ativação muscular é o cálculo do valor RMS (Root Mean Square), que reflete a potência do sinal sem a necessidade de retificação prévia, sendo uma métrica robusta para avaliar o nível de atividade elétrica muscular.

## 2.2 Instrumentação e Condicionamento de Sinais

Os sinais biológicos, como o ECG e o EMG, possuem amplitudes extremamente baixas e são frequentemente contaminados por ruídos externos e internos. Portanto, o estágio de instrumentação e condicionamento é crítico para garantir a integridade da informação antes que ela seja processada digitalmente. Esse processo envolve etapas principais de amplificação, filtragem e conversão analógico-digital.

A primeira etapa é a amplificação. Como os biopotenciais estão na ordem de milivolts ou microvolts, é necessário um ganho elevado para adequar o sinal à faixa dinâmica do conversor A/D. Para isso, utilizam-se amplificadores de instrumentação, que oferecem alta impedância de entrada — essencial para não carregar o circuito equivalente da pele — e uma alta Taxa de Rejeição de Modo Comum (CMRR). Um CMRR elevado (geralmente acima de 90 dB) é crucial para atenuar interferências electromagnéticas, como o ruído de 60 Hz da rede elétrica, que incidem igualmente sobre os cabos e o corpo do paciente (Carr; Brown, 2001).

Em seguida, o sinal passa pela filtragem. Filtros analógicos são empregados para limitar a largura de banda do sinal apenas às frequências de interesse biológico e para remover artefatos. No caso da eletromiografia, por exemplo, recomenda-se filtros passa-faixa para eliminar componentes de corrente contínua (DC) e ruídos de alta frequência. O filtro do tipo Butterworth é frequentemente citado na literatura, como em (Marchetti; Duarte, 2006) e (Balbinot, 2019)), por apresentar uma resposta de frequência plana na banda de passagem, preservando a linearidade da amplitude do sinal biológico sem introduzir ripples (oscilações) indesejados.

Por fim, ocorre a Conversão Analógico-Digital (A/D). Esta etapa transforma o sinal contínuo de tensão em uma sequência discreta de números binários que podem ser processados por um microcontrolador ou computador. Dois parâmetros são fundamentais aqui: a resolução (número de bits), que define a menor variação de tensão detectável, e a frequência de amostragem. De acordo com o Teorema de Nyquist, a frequência de amostragem deve ser, no mínimo, o dobro da maior frequência contida no sinal para evitar o aliasing, um erro de reconstrução onde altas frequências são erroneamente interpretadas como baixas frequências (Marchetti; Duarte, 2006); (Balbinot, 2019).

## 2.3 Filtragem Digital e Inteligência Artificial

O tratamento de sinais biomédicos exige técnicas robustas para garantir que a informação fisiológica não seja mascarada por ruídos. Esta seção aborda desde os métodos clássicos de processamento digital até as abordagens modernas baseadas em aprendizado de máquina.

### 2.3.1 Filtragem Digital

A filtragem digital é o processo matemático realizado sobre um sinal discreto (amostrado) com o objetivo de modificar seu espectro de frequência, atenuando componentes indesejados e preservando a informação relevante. Segundo (Balbinot, 2019), os filtros digitais são classificados fundamentalmente em duas categorias baseadas em sua resposta ao impulso: Filtros de Resposta ao Impulso Finita (FIR) e Filtros de Resposta ao Impulso Infinita (IIR). Os filtros FIR são inherentemente estáveis e possuem fase linear, o que é crucial para evitar distorções na morfologia de sinais como o ECG, embora exijam maior ordem (e custo computacional) para atingir cortes abruptos de frequência.

Já os filtros IIR, conforme explica (Balbinot, 2019), conseguem mimetizar o comportamento de filtros analógicos clássicos (como Butterworth ou Chebyshev) com menor custo computacional e menor atraso de sinal. No entanto, eles podem apresentar instabilidade devido à realimentação e não possuem fase linear perfeita. Embora eficazes para ruídos estacionários (como a interferência de 60 Hz da rede elétrica), técnicas de filtragem digital clássica muitas vezes falham em remover artefatos não-estacionários e complexos, como o ruído de movimento muscular, sem degradar o sinal de interesse, o que motiva a busca por métodos adaptativos baseados em inteligência artificial.

### 2.3.2 Inteligência Artificial (IA)

A Inteligência Artificial (IA) pode ser definida como a capacidade de uma máquina realizar tarefas que, tradicionalmente, exigiriam inteligência humana. Isso inclui habilidades cognitivas como reconhecimento de padrões, compreensão de linguagem natural, percepção visual e tomada de decisão. O campo da IA é vasto e abrange subáreas como robótica, visão computacional e processamento de linguagem natural, buscando mimetizar a capacidade humana de raciocinar e interagir com o ambiente.

No contexto de biosinais, a IA permite que sistemas computacionais analisem grandes volumes de dados fisiológicos para identificar anomalias ou limpar sinais de forma mais eficiente que algoritmos determinísticos. Uma das vertentes mais promissoras para essa tarefa é o *Deep Learning*, que utiliza estruturas matemáticas inspiradas no cérebro biológico para aprender representações complexas de dados a partir de exemplos, sem a necessidade de regras manuais rígidas.

### 2.3.3 Aprendizado de Máquina (*Machine Learning*)

O Aprendizado de Máquina, ou *Machine Learning* (ML), é a ciência de fazer com que computadores ajam sem serem explicitamente programados para cada situação específica. É um subcampo da IA onde algoritmos analisam dados, aprendem com eles e fazem previsões ou decisões baseadas nos padrões encontrados. Segundo (Goodfellow; Bengio; Courville, 2016), as dificuldades enfrentadas por sistemas que dependem de conhecimento codificado rigidamente sugerem que os sistemas de IA precisam da capacidade de adquirir seu próprio conhecimento, extrair padrões de dados brutos. Essa capacidade é conhecida como aprendizado de máquina.

Computadores são historicamente eficientes em tarefas que podem ser formalizadas matematicamente, mas falham em tarefas subjetivas ou intuitivas para humanos, como reconhecer um rosto ou interpretar um sinal ruidoso. O ML resolve isso através de paradigmas de aprendizado, que podem ser: supervisionado (onde o sistema é treinado com pares de entrada-saída rotulados), não supervisionado (onde o sistema busca estruturas ocultas em dados não rotulados) e aprendizado por reforço (baseado em recompensas e punições). Essa capacidade de generalização permite categorizar objetos, prever tendências futuras e, no escopo deste trabalho, distinguir entre o sinal cardíaco real e o ruído de fundo.

### 2.3.4 Redes Neurais Artificiais

As Redes Neurais Artificiais (RNAs) são modelos computacionais inspirados no funcionamento do sistema nervoso central humano. Elas são compostas por unidades de processamento elementares, chamadas de neurônios artificiais, que são interconectadas através de canais de comunicação associados a valores numéricos conhecidos como "pesos". O princípio básico é que a rede aprende ajustando esses pesos: cada vez que um caminho leva a uma decisão correta durante o treinamento, as conexões envolvidas são fortalecidas matematicamente.

Uma RNA é tipicamente organizada em camadas: uma camada de entrada (que recebe os dados brutos), uma ou mais camadas ocultas (onde ocorre o processamento e extração de características) e uma camada de saída. Cada neurônio processa seus dados de entrada através de uma função de ativação não-linear e transmite o resultado para a próxima camada. Essa arquitetura permite que a rede modele relações complexas e não-lineares entre as entradas e as saídas, sendo ideal para o processamento de sinais biológicos que variam dinamicamente.

### 2.3.5 Aprendizado Profundo (*Deep Learning*)

O *Deep Learning* (Aprendizado Profundo) é uma subárea do *Machine Learning* que se concentra no treinamento de redes neurais com muitas camadas ocultas (daí o termo "profundo"). Segundo (Equipe Data Science Academy, 2022), essa profundi-

dade permite que o algoritmo modele e aprenda representações dos dados em múltiplos níveis de abstração. Enquanto as camadas iniciais podem aprender a detectar pequenas variações locais no sinal, as camadas mais profundas combinam essas informações para reconhecer morfologias complexas, como o complexo QRS de um ECG.

Para viabilizar o *Deep Learning*, é necessário um grande volume de dados para treinamento e um alto poder computacional, frequentemente suprido pelo uso de Unidades de Processamento Gráfico (GPUs), que aceleram as operações matriciais massivas envolvidas no processo. Conforme (Goodfellow; Bengio; Courville, 2016), o *Deep Learning* resolve o problema central da aprendizagem de representações, permitindo que o computador construa conceitos complexos a partir de conceitos mais simples, superando a performance de algoritmos tradicionais em tarefas de percepção como visão e audição.

### **2.3.6 Redes Neurais Convolucionais (CNNs)**

As Redes Neurais Convolucionais (CNNs) são uma classe especializada de redes neurais profundas, projetadas originalmente para processar dados que possuem uma topologia de grade, como imagens bidimensionais (2D). No entanto, elas têm se mostrado extremamente eficazes para o processamento de séries temporais unidimensionais (1D), como os sinais de ECG e EMG (Lomoio; Veltri; Guzzi; Liò, 2024). A principal característica das CNNs é o uso da operação matemática de convolução, onde filtros (ou *kernels*) deslizam sobre o sinal de entrada para extrair características locais relevantes, independentemente de sua posição no tempo, conferindo invariância à translação.

Em aplicações de *denoising* (remoção de ruído) de biosinais, as CNNs 1D conseguem aprender a morfologia das ondas características, como a onda R do ECG, e diferenciá-las de ruídos aleatórios (Lomoio; Veltri; Guzzi; Liò, 2024). A arquitetura típica envolve camadas de convolução para extração de *features*, seguidas por camadas de *pooling* (subamostragem), que reduzem a dimensionalidade e aumentam a robustez do modelo a pequenas variações temporais, permitindo uma filtragem adaptativa que preserva a forma do sinal clínico (Goodfellow; Bengio; Courville, 2016; Lomoio; Veltri; Guzzi; Liò, 2024).

### **2.3.7 Autoencoders**

Os Autoencoders são um tipo de rede neural utilizada para aprendizado não supervisionado, cujo objetivo principal é aprender uma representação compacta (codificação) dos dados de entrada. A arquitetura de um autoencoder é composta por duas partes principais: o *Encoder*, que comprime a entrada em uma representação de menor dimensão (espaço latente), e o *Decoder*, que tenta reconstruir a entrada

original a partir dessa representação comprimida. O aprendizado ocorre minimizando a diferença entre a entrada e a saída reconstruída.

Para a redução de ruído, utiliza-se uma variação conhecida como *Denoising Autoencoder* (DAE). Neste método, o modelo é treinado introduzindo-se propositalmente ruído no sinal de entrada, mas forçando a rede a compará-lo com o sinal limpo na saída. Com isso, o Autoencoder é obrigado a aprender as características estruturais robustas do biosinal (como a periodicidade do ECG) e a ignorar o ruído, pois o ruído é aleatório e não possui padrão passível de compressão eficiente no espaço latente. Isso torna os DAEs ferramentas poderosas para limpar sinais biomédicos degradados (Lomoio; Veltri; Guzzi; Liò, 2024).

### 3 Trabalhos Relacionados

Diversos trabalhos na literatura abordam a aquisição e filtragem de biosinais, explorando tanto melhorias em hardware quanto em software. (Kim; Ko, 2016) propuseram um SoC (*System on Chip*) reconfigurável para aquisição de biosinais em plataformas vestíveis de baixa potência, focando na eficiência energética do hardware analógico integrado.

No contexto de melhoria de hardware discreto, (Goel; Singh, 2013) e, mais recentemente, (Pathak et al., 2025) discutiram o design de amplificadores operacionais de baixo ruído especificamente para instrumentação biomédica, demonstrando a importância da escolha de componentes e topologias de baixo ruído (*low-noise*) para garantir a fidelidade do sinal antes da digitalização.

Em relação ao processamento via software, (Singh; Pradhan, 2019) exploraram uma técnica baseada em transformada wavelet modificada para remoção de ruído em ECG, obtendo bons resultados em ruídos gaussianos. Avançando para o uso de *Deep Learning*, (Chandra; Sharma; Kasliwal, 2018) utilizaram Redes Neurais Recorrentes (RNNs) para limpeza de sinal. Mais recentemente, (Lomoio; Veltri; Guzzi; Liò, 2024) desenvolveram o DCAE-SR, um Autoencoder Convolucional para reconstrução de sinais de ECG em super-resolução, evidenciando o potencial de redes neurais profundas na recuperação de detalhes finos do sinal que seriam perdidos por filtros convencionais.

O presente trabalho difere destes por propor uma arquitetura que integra ambas as pontas: um *front-end* analógico customizado de alta precisão (não integrado em SoC fechado) aliado a modelos de IA modernos, visando uma plataforma aberta, de baixo custo e replicável.

## 4 Metodologia e Desenvolvimento

Este capítulo documenta as etapas técnicas de desenvolvimento do projeto, desde a concepção da arquitetura de *hardware* até a implementação dos algoritmos de *software*. A metodologia segue uma abordagem incremental, iniciando pela validação teórica e simulação, seguida pela prototipagem física e integração dos sistemas.

### 4.1 Definição da Arquitetura do Sistema

Para o desenvolvimento de sistemas de instrumentação biomédica, a literatura apresenta diferentes abordagens de topologia. Após análise comparativa de viabilidade e desempenho, optou-se pela \*\*Topologia Híbrida (Condicionamento Analógico + Processamento Remoto)\*\*.

Nesta arquitetura, o *hardware* analógico (o *shield* proposto) realiza o condicionamento crítico — amplificação de instrumentação e filtragem de frequências espúrias —, entregando um sinal limpo e com amplitude adequada ao conversor A/D. O processamento digital pesado, incluindo a filtragem avançada por Inteligência Artificial, é delegado a um computador. Esta decisão permite utilizar microcontroladores de baixo custo como interface de comunicação, garantindo ao mesmo tempo que o sinal digitalizado possua qualidade suficiente para análise.

#### 4.1.1 Detalhamento dos Blocos Funcionais

A arquitetura foi dividida em quatro macro-blocos funcionais:

1. **Bloco de Aquisição Analógica (*Front-End*):** Responsável pela interface com o paciente. Utiliza um Amplificador de Instrumentação (INA) para garantir alta Razão de Rejeição em Modo Comum (CMRR) e estágios de filtragem ativa (Passa-Alta e Passa-Baixa) para delimitar a banda de frequência dos biosinais.
2. **Bloco de Conversão e Controle:** Composto pelo microcontrolador e um Conversor Analógico-Digital (ADC) externo de 16-bits. O uso de um ADC externo visa superar as limitações de resolução dos conversores nativos (geralmente 10-bits), permitindo a detecção de micro-variações no sinal.
3. **Bloco de Comunicação:** Interface (USB/Serial) responsável pelo transporte do

fluxo de dados digitais do *hardware* para a estação de trabalho em tempo real.

4. **Bloco de Processamento Inteligente (Software):** Executado em computador, este módulo recebe os dados brutos, realiza o pré-processamento digital e aplica o modelo de Inteligência Artificial para a remoção final de artefatos complexos e visualização gráfica.

## 4.2 Projeto do Hardware de Aquisição

Esta seção detalha a seleção de componentes e o dimensionamento dos circuitos analógicos.

### 4.2.1 Seleção de Componentes Críticos

A escolha dos componentes priorizou especificações de baixo ruído e alta fidelidade. A Tabela 1 resume a seleção final.

Tabela 1 – Definição dos Componentes Críticos do Hardware

Função	Componente	Justificativa Técnica
Amplificação de Instrumentação	AD620	Padrão médico devido ao alto CMRR ( $> 100$ dB) e ganho ajustável com um único resistor.
Filtragem Ativa (Op-Amps)	OPA2134	Baixíssima distorção e ruído, ideal para bioinstrumentação de alta fidelidade.
Conversão A/D (ADC)	ADS1115	Resolução de 16-bits e interface I2C, superior aos ADCs nativos de microcontroladores comuns.
Microcontrolador	Arduino Uno R3	Plataforma acessível para controle do ADC e interface serial com o PC.
Isolação de Energia	B0505S-1W	Conversor DC-DC para isolar a alimentação do circuito analógico, reduzindo ruído da fonte USB.

### 4.2.2 Dimensionamento dos Filtros Analógicos

O condicionamento analógico inclui filtros ativos de segunda ordem configurados para uma banda passante entre 0,5 Hz e 100 Hz (para ECG) e até 500 Hz (para EMG), visando eliminar componentes DC e ruídos de alta frequência antes da digitalização.

## 4.3 Desenvolvimento do Software e Interface

Paralelamente ao desenvolvimento do hardware, foi implementado o software base para aquisição e visualização dos dados.

### 4.3.1 Ambiente de Simulação e Validação

Para validar a lógica de processamento e a interface gráfica antes da finalização do protótipo físico, desenvolveu-se um módulo de simulação em linguagem Python. Este software utiliza dados reais do banco de dados *MIT-BIH Arrhythmia Database* (PhysioNet), reconhecido mundialmente como padrão para validação de algoritmos de ECG.

Utilizou-se o registro “100” do banco de dados, contendo sinais digitalizados a 360 Hz. O software emula o comportamento do microcontrolador, lendo os dados brutos (.dat) e enviando-os para a rotina de plotagem como se estivessem sendo adquiridos em tempo real. Isso permite testar a estabilidade da taxa de atualização da interface e a visualização da morfologia do complexo QRS (utilizando a derivação MLII do registro).

### 4.3.2 Interface de Visualização em Tempo Real

Foi desenvolvida uma interface gráfica utilizando a biblioteca *Matplotlib*. Para garantir fluidez na plotagem de sinais em alta frequência, utilizou-se a técnica de *blitting*, que redesenha apenas os pixels modificados do gráfico a cada quadro de animação. A interface simula um monitor cardíaco, com varredura contínua no domínio do tempo e controles interativos para pausar a aquisição e salvar capturas de tela para análise posterior.

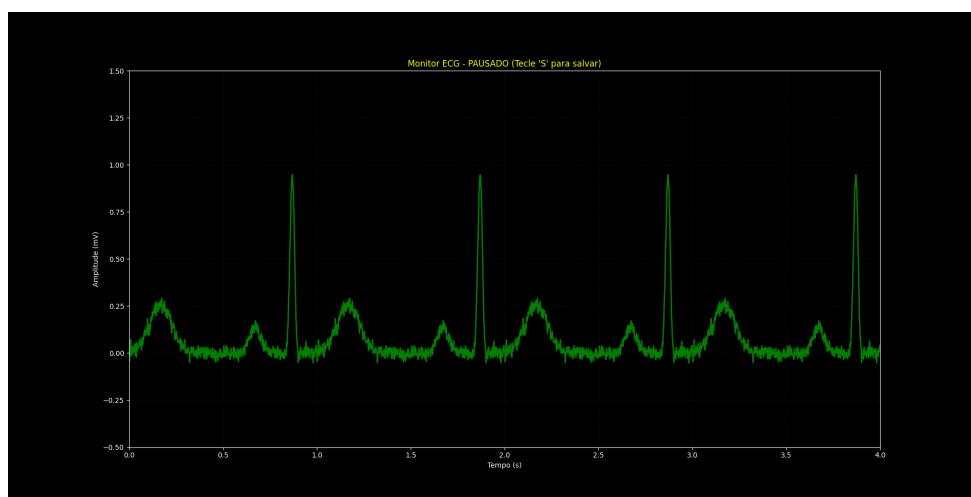


Figura 3 – Interface de aquisição de ECG.

## 4.4 Processamento Digital e Inteligência Artificial

Esta etapa descreverá a implementação dos filtros digitais (FIR/IIR) para remoção de ruído de 60 Hz e o modelo de Rede Neural (Autoencoder) para limpeza avançada do sinal.

## 4.5 Integração e Testes do Sistema

Descrição da integração entre o *shield* analógico, o conversor digital e o software de processamento.

## **5 Resultados**

## **6 Conclusão**

## **Referências**

BALBINOT, A. **Instrumentação e fundamentos de medidas**. 3.ed. Rio de Janeiro: LTC, 2019. v.1.

CARR, J. J.; BROWN, J. M. **Introduction to Biomedical Equipment Technology**. 4.ed. [S.I.]: Prentice Hall, 2001.

CHANDRA, B. S.; SHARMA, R. R.; KASLIWAL, R. K. Deep Recurrent Neural Networks for ECG Signal Denoising. **arXiv preprint arXiv:1807.11551**, [S.I.], 2018.

Equipe Data Science Academy. **Deep Learning Book**: em português, online e gratuito. 2022. [S.I.]: Data Science Academy, 2022. Disponível em: <https://www.deeplearningbook.com.br/>. Acesso em: 4 nov. 2025.

GOEL, A.; SINGH, G. A Novel Low Noise High Gain CMOS Instrumentation Amplifier for Biomedical Applications. **International Journal of Electrical and Computer Engineering (IJECE)**, [S.I.], v.3, n.4, p.531–540, 2013.

GOLDBERGER, A. L. et al. PhysioBank, PhysioToolkit, and PhysioNet: Components of a New Research Resource for Complex Physiologic Signals. **Circulation**, [S.I.], v.101, n.23, p.e215–e220, 2000.

GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. **Deep Learning**. [S.I.]: MIT Press, 2016. <http://www.deeplearningbook.org>.

KIM, J.; KO, H. Reconfigurable Multiparameter Biosignal Acquisition SoC for Low Power Wearable Platform. **Sensors**, [S.I.], v.16, n.12, p.2056, 2016.

LOMOIO, U.; VELTRI, P.; GUZZI, P. H.; LIÒ, P. DCAE-SR: Design of a Denoising Convolutional Autoencoder for Reconstructing Electrocardiogram Signals at Super Resolution. **arXiv preprint arXiv:2404.15307**, [S.I.], 2024.

MARCHETTI, P. H.; DUARTE, M. **Instrumentação em Eletromiografia**. São Paulo: Laboratório de Biofísica, Universidade de São Paulo, 2006.

PATHAK, P. et al. Low-Noise Operational Amplifier Design for Biomedical Instrumentation. **International Journal for Research in Applied Science & Engineering Technology (IJRASET)**, [S.I.], v.13, n.7, p.3086–3093, 2025.

- SINGH, P.; PRADHAN, G. A New Modified Wavelet-Based ECG Denoising. **Health-care Technology Letters**, [S.I.], v.6, n.2, p.28–33, 2019.
- SOUTO, B. G. A. **Introdução à eletrocardiografia clínica básica**: manual para profissionais da atenção primária de saúde. 1.ed. São Carlos: [s.n.], 2016.
- WIDROW, B. et al. Adaptive Noise Cancelling: Principles and Applications. **Proceedings of the IEEE**, [S.I.], v.63, n.12, p.1692–1716, 1975.